Connaissant la latitude, la longitude et la population de sa ville, la structure topologique aide-t-elle à prédire le pays d'un aéroport ? Étude comparative sur un réseau aérien mondial

Yennipena Jérémie Coulibaly
Michel Junior Delanoue

Université Claude Bernard Lyon 1, France
https://github.com/cyjere/rendu-tp-gnn-Coulibaly-and-Delanoue

Résumé Nous étudions la classification de nœuds sur un réseau aérien mondial (3 363 aéroports, 13 547 liaisons) où la tâche consiste à prédire le pays d'un aéroport à partir de ses attributs (longitude, latitude, population) et/ou du graphe des connexions aériennes. Nous comparons des baselines classiques de machine learning et de deep learning (régression logistique, Random Forest, MLP) entraînées sur les seules caractéristiques des nœuds à des réseaux de neurones sur graphe (GCN, GAT, SGC) entraînés soit sur la structure seule, soit sur les caractéristiques combinées à la structure, tous évalués avec des pertes pondérées par classe et le macro-F1 sur cinq splits aléatoires pour gérer le déséquilibre sévère des classes (212 pays, de 1 à 650 aéroports chacun). Contrairement à l'attente habituelle, ajouter la structure du graphe n'améliore jamais le meilleur modèle fondé sur les seules caractéristiques (Random Forest, macro-F1 $0,779 \pm 0,018$) ; la structure seule ne fait pas mieux que le hasard, et sa combinaison avec les caractéristiques dégrade systématiquement les GNN. Nous montrons que cela s'explique par une faible homophilie des arêtes (63,2 % des liaisons relient deux aéroports du même pays), concentrée sur les plus grands hubs internationaux, ce qui dilue le signal géographique sur lequel repose le passage de messages.

Keywords: réseaux de neurones sur graphe, classification de nœuds, déséquilibre de classes, réseau aérien, étude d'ablation

1 Introduction

Les réseaux aériens forment un graphe naturel : les aéroports sont des nœuds, les liaisons directes des arêtes. Nous étudions si la *structure* de ce graphe apporte une information utile pour prédire le **pays** d'un aéroport au-delà de ses seules caractéristiques individuelles, sur un graphe de 3 363 aéroports et 13 547 liaisons (longitude, latitude, population de la ville, pays cible).

Notre problématique : *dans quelle mesure la topologie du réseau aérien améliore-t-elle la prédiction du pays par rapport aux seules caractéristiques individuelles ?* Nous comparons trois conditions : (A) modèles classiques ML/DL sur les seules caractéristiques ; (B) GNN entraînés uniquement sur la structure ; (C) mêmes GNN sur

caractéristiques *et* structure. Cette décomposition isole la contribution propre de la topologie.

2 État de l'art

Pour la condition graphe, nous retenons trois architectures. Le **GCN** [2] moyenne la représentation d'un nœud avec celle de ses voisins, pondérée par le degré. Le **SGC** [6] supprime les non-linéarités et matrices de poids intermédiaires pour ne garder que la propagation, ce qui teste l'apport réel de la non-linéarité. Le **GAT** [4] remplace la moyenne par un poids d'attention appris par paire de nœuds : nous testons s'il peut ignorer des voisins non pertinents en cas de faible homophilie.

Pour les baselines sans graphe, le **Random Forest** [1] est un classifieur non linéaire robuste adapté aux petites features continues, et le **perceptron multicouche** [3] sert de baseline DL sans structure. Le déséquilibre sévère (212 pays, 1 à 650 aéroports) justifie, d'après [5], une pondération de la perte par classe et une évaluation en macro-F1 plutôt qu'en accuracy.

3 Données et protocole

Données. Le graphe est chargé depuis un fichier GraphML : 3 363 nœuds (aéroports), 13 547 arêtes (liaisons), avec pour chaque nœud `lon`, `lat`, `population`, `city_name` et `country` (cible). La cible comporte 212 classes brutes très déséquilibrées (USA : 650 aéroports, médiane : 4, 62 pays à un seul aéroport), ce qui rend impossible toute évaluation sur les plus petites classes.

Filtrage et split. Nous retirons les pays à moins de 3 aéroports (`MIN_CLASS_SIZE=3`), ramenant le problème à 126 classes sur 3 253 nœuds et 12 272 arêtes. Un split stratifié classique échoue encore sur ce seuil : après une première coupe train/reste, de nombreuses classes à 3 éléments n'ont plus qu'un seul exemple, impossible à répartir entre validation et test. Nous utilisons donc un split par classe garantissant au moins un exemple dans chacun des trois ensembles, avec un repli proportionnel pour les classes plus grandes : 69,0 % / 15,5 % / 15,5 %, répété sur 5 seeds.

Features. Les coordonnées brutes `lon/lat` posent deux problèmes : longitude circulaire et singularités aux pôles. Nous testons donc un encodage sur la sphère unité $(x, y, z) = (\cos(\text{lat})\cos(\text{lon}), \cos(\text{lat})\sin(\text{lon}), \sin(\text{lat}))$, combiné à $\log(1+\text{population})$, standardisé sur le train uniquement. Cet encodage améliore tous les modèles (section 4) et devient la représentation par défaut.

Déséquilibre et hyperparamètres. Les modèles sklearn utilisent `class_weight="balanced"` ; les réseaux de neurones (MLP, GCN, GAT, SGC) une `CrossEntropyLoss` pondérée par l'inverse de la fréquence de classe (calculée sur le train de chaque seed). L'architecture du MLP (256 unités, 2 couches, `lr=0,005`, `dropout=0,1`) a été choisie par recherche sur la validation du seed 0 uniquement (macro-F1 : 0,593 → 0,684), jamais sur le test.

4 Expériences et résultats

Toutes les métriques sont moyennées sur 5 seeds (moyenne ± écart-type), macro-F1 étant la métrique principale.

4.1 Condition A : caractéristiques seules

Le tableau 1 compare les modèles sans graphe. L'encodage `xyz` améliore tous les modèles par rapport à `lon/lat` (RF pondéré : $0,577 \rightarrow 0,779$), probablement parce qu'il évite les discontinuités aux frontières et capture mieux les distances relatives. La pondération de la perte aide nettement le Random Forest ($+0,04$ de macro-F1) mais pas le MLP, dont les deux versions sont équivalentes aux écarts-types près : son effet dépend donc du modèle et ne doit pas être supposé systématique. Ce résultat nuance l'idée reçue selon laquelle la pondération est toujours bénéfique.

Modèle (features)	macro-F1	balanced acc.	accuracy
LogReg (xyz)	$0,285 \pm 0,011$	$0,358 \pm 0,008$	$0,491 \pm 0,013$
RF pondéré (lon/lat)	$0,577 \pm 0,007$	$0,631 \pm 0,009$	$0,771 \pm 0,010$
RF pondéré (xyz)	$\mathbf{0,779 \pm 0,018}$	$\mathbf{0,816 \pm 0,013}$	$0,868 \pm 0,010$
RF non pondéré (xyz)	$0,741 \pm 0,026$	$0,769 \pm 0,025$	$\mathbf{0,886 \pm 0,011}$
MLP pondéré (xyz)	$0,613 \pm 0,011$	$0,672 \pm 0,014$	$0,785 \pm 0,009$
MLP non pondéré (xyz)	$0,618 \pm 0,035$	$0,658 \pm 0,035$	$0,846 \pm 0,019$

TABLE 1 – Condition A (features seules), 5 seeds. Meilleur macro-F1 en gras.

4.2 Conditions B et C : structure seule, puis features + structure

Le tableau 2 ajoute les GNN, entraînés soit sur une feature constante (B : topologie seule), soit sur les features `xyz` (C : features + structure), avec la même perte pondérée et le même protocole à 5 seeds.

Modèle (condition)	macro-F1	balanced acc.	accuracy
RF pondéré (A, xyz)	$\mathbf{0,779 \pm 0,018}$	$\mathbf{0,816 \pm 0,013}$	$\mathbf{0,868 \pm 0,010}$
GCN (B, topologie seule)	$0,003 \pm 0,004$	$0,013 \pm 0,009$	$0,007 \pm 0,005$
GAT (B, topologie seule)	$0,000 \pm 0,000$	$0,008 \pm 0,000$	$0,012 \pm 0,006$
SGC (B, topologie seule)	$0,000 \pm 0,000$	$0,006 \pm 0,003$	$0,002 \pm 0,001$
GCN (C, features+structure)	$0,493 \pm 0,020$	$0,552 \pm 0,023$	$0,698 \pm 0,011$
GAT (C, features+structure)	$0,252 \pm 0,042$	$0,331 \pm 0,038$	$0,474 \pm 0,049$
SGC (C, features+structure)	$0,370 \pm 0,031$	$0,426 \pm 0,032$	$0,579 \pm 0,032$

TABLE 2 – Conditions B et C, 5 seeds, mêmes features `xyz` que le Random Forest de référence (A).

Deux constats. La topologie seule (B) ne porte quasiment aucun signal : les macro-F1 ($0,000$ à $0,003$) sont au niveau du hasard sur 126 classes ($1/126 \approx 0,008$). La structure

du réseau aérien, prise isolément, n'apporte donc aucune information discriminante : les connexions aériennes ne sont pas un proxy suffisant de l'appartenance nationale. Ajouter la structure aux features (C) ne bat jamais le Random Forest de la condition A et dégrade même les performances par rapport aux mêmes features sans graphe : le meilleur GNN (GCN) perd 0,29 point de macro-F1. Ce phénomène s'explique par la propagation de bruit : les voisins étrangers injectent des informations contradictoires qui perturbent la représentation apprise, alors que le Random Forest, ignorant le graphe, se concentre sur les seules caractéristiques géographiques.

5 Discussion et conclusion

Pourquoi la structure n'aide pas. Les GNN à passage de messages supposent implicitement que les voisins partagent la même classe. Or seulement **63,2 %** des arêtes (7 761 sur 12 272) relient deux aéroports du même pays. Ce déficit d'homophilie est concentré sur les plus gros hubs, qui pèsent le plus dans l'agrégation : Paris (80 % de voisins étrangers), Londres (93 %), Francfort (91 %), Amsterdam (99 %) — contre 24 % pour Chicago, à dominante domestique. Les GNN sont donc pénalisés par les hubs fortement connectés à l'international, qui brouillent le signal local ; à l'inverse, un pays à réseau domestique dense comme les États-Unis pourrait bénéficier d'une agrégation plus homogène.

Diagnostic par classe. Les erreurs du meilleur modèle (Random Forest, xyz) ne sont pas aléatoires : le macro-F1 moyen passe de $0,674$ pour les classes à ≤ 5 aéroports d'entraînement (n=46) à $0,858$ au-delà (n=80), et 7 des 8 pires classes sont confondues avec leur voisin géographique réel et plus représenté (Bosnie $\rightarrow$ Croatie, Cambodge $\rightarrow$ Thaïlande, Cameroun $\rightarrow$ Nigeria). Un petit pays n'échoue donc pas par manque de données seul, mais quand sa frontière de décision est absorbée par un grand voisin dans l'espace des features.

Conclusion. Sur ce jeu de données, la structure topologique du réseau aérien **n'améliore pas** la prédiction du pays : elle la dégrade, car la connectivité aérienne est largement internationale et la position géographique porte déjà l'essentiel du signal. Limites : un seul graphe/une seule tâche, d'autres architectures non testées (GraphSAGE, APPNP), et l'observation sur Chicago à vérifier systématiquement.

Références

1. Breiman, L. : Random forests. Machine Learning 45(1), 5–32 (2001)
2. Kipf, T.N., Welling, M. : Semi-supervised classification with graph convolutional networks. In : International Conference on Learning Representations (ICLR) (2017)
3. Rumelhart, D.E., Hinton, G.E., Williams, R.J. : Learning representations by back-propagating errors. Nature 323(6088), 533–536 (1986)
4. Veličković, P., Cucurull, G., Casanova, A., Romero, A., Liò, P., Bengio, Y. : Graph attention networks. In : International Conference on Learning Representations (ICLR) (2018)
5. Wang, L., Han, M., Li, X., Zhang, N., Cheng, H. : Review of classification methods on unbalanced data sets. IEEE Access 9, 64606–64628 (2021)
6. Wu, F., Souza, A., Zhang, T., Fifty, C., Yu, T., Weinberger, K. : Simplifying graph convolutional networks. In : Proceedings of the 36th International Conference on Machine Learning (ICML) (2019)